
LAB4: MLflow: Experimentacion y Despliegue de Modelos

Ignacio González Peris

9 de marzo de 2026

Abstract

En este laboratorio se presenta un flujo de experimentación y despliegue de modelos con *MLflow* aplicado al dataset PIMA Diabetes. Se parte de un experimento base con *LogisticRegression* y posteriormente se comparan múltiples configuraciones de *LogisticRegression*, *RandomForest* y *GradientBoosting* mediante *Grid Search* y selección orientada a criterios clínicos.

Dado que en el contexto de diabetes un falso negativo es más costoso que un falso positivo, la métrica prioritaria es el *recall*. A partir de este criterio se registran los mejores modelos en el *Model Registry* y se selecciona un modelo final para despliegue. Finalmente, se comparan las métricas observadas en validación con las métricas reales en un conjunto de test reservado, extrayendo conclusiones sobre generalización, sesgo de validación y utilidad práctica de *MLflow* para la gestión del ciclo de vida del modelo.

Keywords: MLflow, LogisticRegression, GradientBoosting, RandomForest, Diabetes, Model Registry, Recall, F1-score

Contents

1	Experimento de prueba	3
2	Tabla de modelos registrados	3
3	Criterio médico de selección	3
4	Modelo seleccionado para despliegue	4
5	Métricas reales sobre test set	4
5.1	Matriz de confusión	4
5.2	Classification Report	4
6	Conclusiones	4

1 Experimento de prueba

Se entrenó una *LogisticRegression* como baseline sobre el dataset PIMA Diabetes (768 muestras, 8 *features*, *split* 80/20 estratificado).

Table 1 – Resultados del experimento baseline.

Métrica	Valor
Accuracy	0.7143
Precision	0.6087
Recall	0.5185
F1	0.5600

El modelo fue registrado en MLflow como `diabetes-prueba-lr`.

2 Tabla de modelos registrados

Se realizaron *Grid Search* con 3 familias de modelos ($16 + 48 + 18 = 82$ combinaciones), seleccionando las top-3 por *CV Recall* y reevaluando en validación.

Table 2 – Modelos registrados en MLflow.

Modelo	Parámetros clave	CV Recall	Val Recall	Val F1	Val Acc	Razón de registro
GradientBoosting-top1	lr=0.2, depth=3, n_est=100	0.5987	0.9444	0.9714	0.9805	Mejor recall
RandomForest-top1	balanced, depth=3, split=5, n_est=200	0.7378	0.8519	0.7480	0.7987	Mejor F1
RandomForest-top2	balanced, depth=3, split=2, n_est=200	0.7378	0.8519	0.7480	0.7987	Alternativa

Otros modelos destacados (no registrados):

Table 3 – Otros modelos destacados no registrados.

Modelo	CV Recall	Val Recall	Val F1	Val Acc
LR-top1 (C=0.01, balanced, l2)	0.7432	0.8148	0.7213	0.7792
LR-top2 (C=0.1, balanced, l1)	0.7377	0.8148	0.7395	0.7987
GB-top2 (lr=0.1, depth=3, n_est=50)	0.5987	0.7222	0.7879	0.8636
GB-top3 (lr=0.1, depth=3, n_est=100)	0.5933	0.7593	0.8367	0.8961

3 Criterio médico de selección

En el contexto de diabetes, un **falso negativo** (paciente diabético clasificado como sano) es más peligroso que un **falso positivo** (paciente sano derivado a pruebas adicionales).

Por ello, el criterio de selección prioriza:

1. **Recall** ≥ 0.65 - minimizar falsos negativos.
2. **F1** - equilibrar precisión sin sacrificar demasiado recall.
3. **Accuracy** - desempate.

Todos los modelos con `class_weight="balanced"` superaron el umbral de recall, confirmando que la ponderación de clases es esencial en datasets desbalanceados.

4 Modelo seleccionado para despliegue

- **Nombre en Model Registry:** diabetes-best
- **Tipo:** GradientBoosting
- **Parámetros:** `learning_rate=0.2`, `max_depth=3`, `n_estimators=100`
- **Razón:** Mayor recall en validación (0.9444) con excelente F1 (0.9714)

Nota: El alto rendimiento en validación puede deberse a que el modelo fue reentrenado en train+val y evaluado en el mismo val. Las métricas reales sobre test set (sección 5) serán más representativas del rendimiento en producción.

5 Métricas reales sobre test set

Modelo diabetes-best (GradientBoosting) evaluado sobre el test set reservado (77 muestras, 10% del dataset).

Table 4 – Métricas del modelo seleccionado sobre test set.

Métrica	Valor
Accuracy	0.8312
Precision	0.7500
Recall	0.7778
F1	0.7636

5.1 Matriz de confusión

TN=43 FP=7
FN=6 TP=21

5.2 Classification Report

	precision	recall	f1-score	support
No diabetes	0.88	0.86	0.87	50
Diabetes	0.75	0.78	0.76	27
accuracy			0.83	77

El recall en test (0.78) baja respecto a validación (0.94), lo cual es esperado: las métricas de validación estaban infladas porque el modelo fue reentrenado en train+val y evaluado sobre el mismo val. El test set confirma un rendimiento sólido y realista, con recall > 0.65 cumpliendo el criterio médico.

6 Conclusiones

- **Tradeoff precision-recall:** En diagnóstico médico, aceptamos más falsos positivos a cambio de detectar más casos reales. El recall es la métrica prioritaria.

- **class_weight="balanced"**: Los modelos con ponderación balanceada mejoran consistentemente el recall. Todos los modelos top tienen esta configuración.
- **Limitaciones del dataset**: Las columnas Glucose, BloodPressure, SkinThickness, Insulin y BMI contienen valores 0 que representan datos faltantes. No se realizó imputación (fuera del *scope*), lo que puede afectar el rendimiento de los modelos.
- **Sobreajuste en validación**: El GradientBoosting pasó de recall=0.94 en validación a recall=0.78 en test. Esto confirma que reentrenar en train+val y evaluar en val infla las métricas. El test set reservado (10%) da la estimación realista.
- **Valor de MLflow**: Permite comparar sistemáticamente 82 configuraciones, reproducir experimentos, y desplegar modelos con un comando. El Model Registry facilita la gestión del ciclo de vida del modelo.

